



黄之豪

20110980005

更详细的相关内容会在作业截止提交后上传github: <https://github.com/HUANGZHIHAO1994/Financial-risk-management.git>

一、涉及内容

第二次作业涉及:

- **蒙特卡洛计算亚式期权以及希腊字母计算 (第一题)**: 样本路径生成、亚式期权定价、置信区间估计、delta、vega使用pathwise method、gamma使用likelihood ratio method计算
- **Longstaff-Schwartz method 计算美式看跌 (第二题)**: 样本路径生成、Tsitsiklis et al.(1999)方法、动态规划

二、项目结构及相关说明

1. 结构及说明

```
├─ config.py
├─ hw2_1.py
├─ hw2_1.txt
├─ hw2_2_compare.txt
├─ hw2_2.py
├─ hw2_2.txt
├─ LSM.py
├─ project_structure.txt
├─ __pycache__
│   └─ config.cpython-36.pyc
│       └─ hw2_1.cpython-36.pyc
├─ references
│   └─ LongstaffSchwartzAmericanOptionsLeastSquareMonteCarlo.pdf
│       └─ Tsitsiklis.pdf
│           └─ 随机波动率模型下基于精确模拟算法的期权计算理论.pdf
├─ Report.pdf
└─ requirements.txt

2 directories, 15 files
```

其中, 以下是主要文件:

config.py 是两道题都使用的全局变量文件, 第一题使用 hw2_1.py, 第二题使用 hw2_1.py 和 hw2_2.py 以及与 LSM.py 对比

2. 环境

```
pip install -r requirements.txt
```

三、第一题 (hw2_1.py)

为了便于复现结果，本次作业统一使用 `np.random.seed(1234)` 作为随机种子！

相关数值计算结果可见于 5. 模拟结果

1. 生成样本路径

给定条件: $S(t_0)=30$, $K=30$, $r=3\%$, $\sigma=35\%$, $T=1$

使用以下公式生成样本路径:

$$S(t_{i+1}) = S(t_i) \exp\left\{\left(r - \frac{\sigma^2}{2}\right)(t_{i+1} - t_i) + \sigma\sqrt{t_{i+1} - t_i}Z_{i+1}\right\} \quad i = 0, 1, \dots, 251$$
$$Z_{i+1} \sim N(0, 1)$$

$$\text{Sample path}_{252 \times 10000} = \begin{pmatrix} s(t_1)_1 & s(t_1)_2 & \cdots & s(t_1)_{10000} \\ s(t_2)_1 & s(t_2)_2 & \cdots & s(t_2)_{10000} \\ \vdots & \vdots & \ddots & \vdots \\ s(t_{252})_1 & s(t_{252})_2 & \cdots & s(t_{252})_{10000} \end{pmatrix}$$

本次作业中, $\Delta t = t_{i+1} - t_i = \frac{1}{252}$, 实现样本路径可通过生成 (252, 10000) 维的标准正态随机数, 之后逐行计算 $S(t)$, 具体可见 `generate_samples` 方法:

```
def generate_samples():
```

2. 亚式期权定价

生成样本路径后, 亚式期权可根据下式定价:

$$\bar{S}_i = \frac{1}{252} \sum_{m=1}^{252} S(t_m)_i$$
$$\bar{c} = \frac{1}{10000} \sum_{i=1}^{10000} e^{-rT} (\bar{S}_i - K)^+$$

详情可见 `calculate` 方法:

```
def calculate(stock_matrix, d_st_d_sigma_matrix, standard_normal_matrix):
```

3. 置信区间计算

按下式计算置信区间：

$$c_i = e^{-rT} (\bar{S}_i - K)^+$$
$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (c_i - \bar{c})^2$$
$$(\bar{c} - t_{1-\frac{\alpha}{2}}(n-1) \frac{s}{\sqrt{n}}, \bar{c} + t_{1-\frac{\alpha}{2}}(n-1) \frac{s}{\sqrt{n}})$$

详情可见 calculate 方法：

```
def calculate(stock_matrix, d_st_d_sigma_matrix, standard_normal_matrix):
```

4. 希腊字母计算

4.1 delta计算

亚式期权 delta 计算在 lecturenote6 中已经给出公式，此处不再重复推导，公式如下：

$$\alpha'(S_0) = E[e^{-rT} 1_{\{\bar{S} > K\}} \frac{\bar{S}}{S_0}] \approx \frac{1}{n} \sum_{i=1}^n e^{-rT} 1_{\{\bar{S}_i > K\}} \frac{\bar{S}_i}{S_0}$$

delta 计算相对简单，并不需要新增计算，详情可见 calculate 方法：

```
def calculate(stock_matrix, d_st_d_sigma_matrix, standard_normal_matrix):
```

4.2 vega计算

亚式期权 vega 计算与 lecturenote6 中 delta 计算推导相似，但要比 delta 复杂，具体推导如下：

$$\alpha(\sigma) = E[e^{-rT} (\bar{S} - K)^+] = E[Y(\sigma)]$$

$$\frac{d}{d\sigma} Y(\sigma) = e^{-rT} 1_{\{\bar{S} > K\}} \frac{d}{d\sigma} \bar{S}$$

$$\frac{d}{d\sigma} \bar{S} = \frac{1}{m} \sum_{i=1}^m \frac{d}{d\sigma} S(t_i)$$

根据 lecturenote6 中 $S(t_i)$ 计算 $\frac{d}{d\sigma} S(t_i)$ 得：

$$S(t_i) = S(t_0) \exp\left\{\left(r - \frac{\sigma^2}{2}\right)t_i + \sigma\sqrt{\Delta t}(Z_1 + \dots + Z_i)\right\}$$

$$\frac{d}{d\sigma} S(t_i) = S(t_i)(-\sigma t_i + \sqrt{\Delta t}(Z_1 + \dots + Z_i))$$

综上得到 vega 计算式：

$$\alpha'(\sigma) = E[e^{-rT} 1_{\{\bar{S} > K\}} \frac{1}{m} \sum_{i=1}^m S(t_i)(-\sigma t_i + \sqrt{\Delta t}(Z_1 + \dots + Z_i))]$$

可以看到，vega 与 delta 计算差别主要在 $\frac{d}{d\sigma} S(t_i)$ 上，此处采用在生成样本路径时一起计算 $\frac{d}{d\sigma} S(t_i)$ 的方法，详情可见 generate_samples 方法中 d_st_d_sigma_matrix 和 calculate 方法：

```
d_st_d_sigma_matrix[i] = stock_matrix[i] * (-VOLATILITY * DELTA_T * (i + 1) +
np.sqrt(DELTA_T) * sum_of_standard_normal_matrix[i])

def calculate(stock_matrix, d_st_d_sigma_matrix, standard_normal_matrix):
```

4.3 gamma计算

亚式期权 gamma 计算使用了 likelihood ratio method，是希腊字母计算中最复杂的，也是最容易出错的，此处使用符号与 lecturenote6 中一致，具体推导如下：

$$\begin{aligned}\alpha''(\theta) &= \int_{\mathbb{R}^m} g(\vec{x}) \frac{\partial^2 f(\vec{x}; \theta)}{\partial \theta^2} d\vec{x} \\ &= \int_{\mathbb{R}^m} g(\vec{x}) \frac{\frac{\partial^2 f(\vec{x}; \theta)}{\partial \theta^2}}{f(\vec{x}; \theta)} f(\vec{x}; \theta) d\vec{x} \\ &= E[g(\vec{x}) \frac{\frac{\partial^2 f(\vec{x}; \theta)}{\partial \theta^2}}{f(\vec{x}; \theta)}]\end{aligned}$$

4.3.1 错误的做法

值得注意的是，必须从上式开始推导，不能使用如下方法推导：

$$\alpha''(\theta) = \frac{d}{d\theta} \alpha'(\theta) = \frac{\partial}{\partial \theta} E[g(\vec{x}) \frac{\partial}{\partial \theta} \log[f(\vec{x}; \theta)]]$$

原因在于上式第二个等号不成立

$$\begin{aligned}\frac{\partial}{\partial \theta} E[g(\vec{x}) \frac{\partial}{\partial \theta} \log[f(\vec{x}; \theta)]] &= E[g(\vec{x}) \frac{\partial}{\partial \theta} (\frac{\frac{\partial f(\vec{x}; \theta)}{\partial \theta}}{f(\vec{x}; \theta)})] \neq E[g(\vec{x}) \frac{\frac{\partial^2 f(\vec{x}; \theta)}{\partial \theta^2}}{f(\vec{x}; \theta)}] \\ \frac{f''(x)}{f(x)} &\neq (\frac{f'(x)}{f(x)})'\end{aligned}$$

因此，求 gamma 不能通过求得 delta 的结果： $\frac{\partial \log(g(S_1, \dots, S_m))}{\partial S_0} = \frac{Z_1}{S_0 \sigma \sqrt{\Delta t}}$ 基础上继续求导得到，如此做法在最终 gamma 结果中会少了 Z_1^2 项。

4.3.2 正确的做法

只能利用 $\alpha''(\theta) = E[g(\vec{x}) \frac{\frac{\partial^2 f(\vec{x}; \theta)}{\partial \theta^2}}{f(\vec{x}; \theta)}]$ 求 gamma, 可利用中间结果 $\frac{\partial \log(g(S_1, \dots, S_m))}{\partial S_0} = \frac{\log S_1 - \log S_0 - (r - \frac{\sigma^2}{2})\Delta t}{S_0 \sigma^2 \Delta t}$, 具体使用如下:

$$\begin{aligned}\frac{\partial g(S_1, \dots, S_m)}{\partial S_0} &= \frac{\partial \log(g(S_1, \dots, S_m))}{\partial S_0} g(S_1, \dots, S_m) \\ \frac{\partial^2 g(S_1, \dots, S_m)}{\partial S_0^2} &= \frac{\partial}{\partial S_0} \left(\frac{\log S_1 - \log S_0 - (r - \frac{\sigma^2}{2})\Delta t}{S_0 \sigma^2 \Delta t} g(S_1, \dots, S_m) \right) \\ &= \left(\frac{-1}{S_0^2 \sigma^2 \Delta t} - \frac{Z_1}{S_0^2 \sigma \sqrt{\Delta t}} \right) g(S_1, \dots, S_m) + \frac{\log S_1 - \log S_0 - (r - \frac{\sigma^2}{2})\Delta t}{S_0 \sigma^2 \Delta t} \frac{\partial g(S_1, \dots, S_m)}{\partial S_0} \\ &= \left(\frac{-1 - Z_1 \sigma \sqrt{\Delta t}}{S_0^2 \sigma^2 \Delta t} \right) g(S_1, \dots, S_m) + \left(\frac{\log S_1 - \log S_0 - (r - \frac{\sigma^2}{2})\Delta t}{S_0 \sigma^2 \Delta t} \right)^2 g(S_1, \dots, S_m) \\ &= \frac{Z_1^2 - 1 - Z_1 \sigma \sqrt{\Delta t}}{S_0^2 \sigma^2 \Delta t} g(S_1, \dots, S_m)\end{aligned}$$

进而得到

$$\alpha''(\theta) = E[e^{-rT} (\bar{S} - K)^+ \frac{Z_1^2 - 1 - Z_1 \sigma \sqrt{\Delta t}}{S_0^2 \sigma^2 \Delta t}]$$

上述推导也可参考下面文献的 P1546-1547 (文章中分母 S_0 还是少了个平方, 但总体推导思路正确)

[1]马俊美,杨宇婷,顾桂定,徐承龙.随机波动率模型下基于精确模拟算法的期权计算理论[J].同济大学学报(自然科学版),2017,45(10):1539-1548.

具体代码实现可见 calculate 方法中:

```
pathwise_gamma = np.mean(np.exp(-RISK_FREE_RATE_OPTION * EXPIRES_ANNUALIZE) *
np.maximum(0, s_i_bar_vector - K) * (np.power(standard_normal_matrix[0], 2) -
standard_normal_matrix[0] * VOLATILITY * np.sqrt(DELTA_T) - 1) / (np.power(S_0 *
VOLATILITY, 2) * DELTA_T))
```

5. 模拟结果

计算结果也可见于: hw2_1.txt

注意: gamma 由于是二阶导, 本次作业也只取了10000个 sample path, 因此随机种子设置不同会导致结果相差非常大。因此再次强调: 以下是设定 np.random.seed(1234) 下计算出的结果:

Asion option price	2.633973843392969
confidence interval	[2.5490384687955756, 2.7189092179903622]
delta	0.5529336723428989
vega	6.873542661601932
gamma	0.1917685559177979

四、第二题 (hw2_2.py)

由于洪教授上课 lecturenote5 中 Longstaff-Schwartz 方法与 Longstaff-Schwartz (2001): Valuing American Options by Simulation: A Simple Least-Squares Approach 原文有所不同, 故此处使用了三种方法并比较结果和运行速度。

数值计算结果见 5.计算结果

1. 生成样本路径

参考第一题生成样本路径方法, 完全一样

2. Tsitsiklis et al.(1999)方法

Roy J N T B V . Optimal Stopping of Markov Processes: Hilbert Space Theory, Approximation Algorithms, and an Application to Pricing High-Dimensional Financial Derivatives[J]. Automatic Control IEEE Transactions on, 1999, 44(10):1840-1851.

格拉瑟曼, Paul Glasserman, Glasserman, et al. 金融工程中的蒙特卡罗方法[M]. 高等教育出版社, 2013.

其实, 洪教授 lecturenote5 中的 Longstaff-Schwartz 方法是 Tsitsiklis et al. (1999) 方法, 通过多项式回归拟合 Continue Value 之后, 进而通过下式使用从后向前逐步递推方法获取期权价值 (具体算法由于讲义中有不在此处详述):

$$\widetilde{V}_{m-1,j} = \max\{(K - S_{m-1,j})^+, C_{m-1}(S_{m-1,j})\}$$

2.1 优点

优点是计算简单、理解容易, 相比 Longstaff-Schwartz (2001) 原文中的方法少了判断 in the money 以及动态规划部分, 理解也相对容易是一种非常直观的 **拟合—继续价值与立即行权价值取最大—继续向前计算** 流程。

2.2 缺点

1. 容易高估期权价值。从上式也可以看到, 如果 Continue Value 拟合值 $C_{m-1}(S_{m-1,j})$ 十分大 (高估许多), 是会影响后续许多步的拟合值, 也可能最终直接影响期权价值 V_0 。那为什么说这个方法容易高估呢, 因为拟合值 $C_{m-1}(S_{m-1,j})$ 十分小的时候会选取 $(K - S_{m-1,j})^+$ 作为下一次拟合依据, 影响并不是那么大。
2. 由1, 自然地, 该方法对拟合精度要求高。
3. 该方法与常规美式期权 (二叉树计算) 思路并不同, 拟合出 Continue Value, 不仅用作判断是否 exercise, 还可能用到下一次拟合和以及影响期权定价。

具体实现可见 tsitsiklis 方法:

```
def tsitsiklis(stock_matrix):
```

3. Longstaff-Schwartz

Longstaff F A , Schwartz E S . Valuing American Options by Simulation: A Simple Least-Squares Approach[J]. Review of Financial Studies, 2001(1):113-147.

格拉瑟曼, Paul Glasserman, Glasserman, et al. 金融工程中的蒙特卡罗方法[M]. 高等教育出版社, 2013.

Longstaff-Schwartz(2001) 原文P117: "We use only in-the-money paths since it allows us to better estimate the conditional expectation function in the region where exercise is relevant and significantly improves the efficiency of the algorithm."

上述说明Longstaff-Schwartz(2001)只选择那些 in-the-money paths 进行多项式回归拟合, 因为与二叉树计算美式看跌期权思路一致: 当期如果立即执行期权收益为0, 那么不管Continue Value是多少, 总是会选择执行。

通过查看 Longstaff-Schwartz(2001) 原文中 P115-120例子可以发现 (文章相对易懂可看):

1. 拟合的Continue Value仅用作判断是否当期执行, 如果确定当期执行会把后续现金流全设为0 (已经执行自然没有现金流), 这一点也符合二叉树计算美式看跌期权的思路
2. 拟合用的Y是 in-the-money paths 中向后追述第一个也是唯一——一个现金流大于0的值。因为 Longstaff-Schwartz(2001) 原文方法考虑整体现金流, 因此最终期权价值是整个现金流矩阵折现得到, 相关计算也使用了动态规划思想

《金融工程中的蒙特卡罗方法》中 P434 也提及了两种方法差别。

3.1 优点

计算更精准, 并且计算思路与二叉树方法计算美式看跌期权价格一致。

3.2 缺点

动态规划耗时较长, 且程序相对不易实现

本次作业针对其耗时较长的缺点, 通过程序设计可以优化大大缩短时长

3.3 优化思路

首先要深入理解 Longstaff-Schwartz 方法, 该方法其实每一步都分为 out-of-the-money 和 in-the-money, 再通过对 in-the-money 细分, 最终形成三部分: out-of-the-money、continue、exercise, 其中后两部分是 in-the-money 部分的细分。

优化方法: 还是利用 Tsitsiklis et al. (1999) 方法逐步向前推进的思路, 具体地, 每一步: 把那些 out-of-the-money 的以及判断要 continue 的 sample path 的上一期现金流折现到当前步, 其余判断要 exercise 的 sample path 自然地选择 $K - S_t$ 作为当期现金流, 如此逐步向前迭代下去。

这么做的好处是: 实质上每次计算只需用当前步和上一期的现金流数据, 而动态规划需要用整个现金流矩阵, 并且动态规划判断要 continue 时向后追述现金流以及判断要 exercise 时向后将现金流都设置为0都是十分耗时的。

详细实现可见 longstaff_schwartz 方法:

```
def longstaff_schwartz(stock_matrix):
```

4. 结合Longstaff-Schwartz和Tsitsiklis

优缺点也介于两种方法之间。

与 Longstaff-Schwartz 方法相同的是，把那些 out-of-money 的现金流折现；但是，不同的是，根据判断结果确定要 continue 时，现金流使用多项式回归拟合的 Continue Value，具体可见 longstaff_schwartz_combine_tsitsiklis 方法

```
def longstaff_schwartz_combine_tsitsiklis(stock_matrix):
```

5. 计算结果

5.1 说明以及结果展示

其实 Longstaff-Schwartz 方法已有学者在github上实现：<https://github.com/aminjellali/Longstaff-and-Schwartz.git>

该作者完全使用原文动态规划思路进行编程，我对他的程序稍作修改之后使不同程序能在结果上一致，进而进行性能比较：

1. 该作者期权参数与题目给定不同
2. 该作者使用了Laguerre多项式，与Longstaff_Schwartz(2001)和洪教授讲义使用一般多项式不同

修改完形成 LSM.py 文件。

我自己写的程序是 hw2_2.py 程序中有上述提及的三种方法实现，比较结果如下（结果也保存在了 hw2_2.txt 和 hw2_2_compare.txt 文件中）：

hw2_2.py	
Longstaff_Schwartz (2001)计算用时	2.655221536755562
Longstaff_Schwartz (2001) price	3.8151357853081094
Combine of (Longstaff_Schwartz, 2001) and Tsitsiklis et al, 1999) price	3.8306045815398466
Tsitsiklis et al. (1999) or the lecturenote5 from Prof. L. Jeff Hong price	4.4527336640111255
LSM.py	
Longstaff_Schwartz (2001) price	3.815135785308124
Longstaff_Schwartz (2001)计算用时	172.07279300689697

5.2 总结

1. 可以看到计算结果一致情况下，hw2_2.py 中 Longstaff_Schwartz(2001) 方法用时快了65倍（其实有一种情况是必须使用动态规划的，那就是想要知道执行期权的具体时刻，即 Longstaff Schwartz (2001) P119 stopping rule 表格。如果只关心定价则可使用 hw2_2.py)
2. 可以看到，Tsitsiklis 方法确实会高估期权价值，两者结合也确实介于两者之间
3. **注：**同样的参数，第一次作业美式看跌期权计算结果为：3.7557436745895885，显然 Longstaff Schwartz(2001) 是与该结果最接近的，这与他们思路相同也有关系